



Identificación de estados fenológicos de la flor de durazneros mediante visión por computadora

Autor:

Ing. Héctor Luis Sánchez Márquez

Director:

Ing. Juan Ignacio Cavalieri (FIUBA)

Codirector:

Esp. Lic. Nicolás Eduardo Horro (INVAP S.E.)

*Esta planificación fue realizada en el curso de Gestión de proyectos
entre el 22 de agosto de 2023 y el 10 de octubre de 2023.*

Índice

1. Descripción técnica-conceptual del proyecto a realizar	5
1.1 Introducción general	5
1.2 Marco de la propuesta	6
2. Identificación y análisis de los interesados	7
3. Propósito del proyecto	7
4. Alcance del proyecto	8
5. Supuestos del proyecto.	8
6. Requerimientos	8
7. Historias de usuarios (<i>Product backlog</i>).	9
8. Entregables principales del proyecto	10
9. Desglose del trabajo en tareas	11
10. Diagrama de Activity On Node.	11
11. Diagrama de Gantt	13
12. Presupuesto detallado del proyecto	15
13. Gestión de riesgos	15
14. Gestión de la calidad	17
15. Procesos de cierre	19

Registros de cambios

Revisión	Detalles de los cambios realizados	Fecha
0	Creación del documento.	22 de agosto de 2023
1	Se completa hasta el punto 5 inclusive.	5 de septiembre de 2023
2	Aplicación de las correcciones de la revisión 1. Se completa hasta el punto 9 inclusive.	12 de septiembre 2023
3	Aplicación de las correcciones de la revisión 2. Se completa hasta el punto 12 inclusive.	18 de septiembre 2023
4	Aplicación de las correcciones de la revisión 3. Se completa hasta el punto 15 inclusive.	25 de septiembre 2023
4.1	Aplicación de las correcciones de la revisión 4.	1 de octubre 2023

Acta de constitución del proyecto

Buenos Aires, 22 de agosto de 2023

Por medio de la presente se acuerda con el Ing. Héctor Luis Sánchez Márquez que su Trabajo Final de la Carrera de Especialización en Inteligencia Artificial se titulará “Identificación de estados fenológicos de la flor de durazneros mediante visión por computadora”, consistirá esencialmente en desarrollar un algoritmo que identifique flores y su estado a partir de fotos de varetas, y tendrá un presupuesto preliminar estimado de 620 horas de trabajo y \$13.939.500 pesos argentinos de costos, con fecha de inicio 22 de agosto de 2023 y fecha de presentación pública abril de 2024.

Se adjunta a esta acta la planificación inicial.

Dr. Ing. Ariel Lutenberg
Director posgrado FIUBA

Dr. Gerardo Sánchez
Instituto Nacional de Tecnología Agropecuaria (INTA)

Ing. Juan Ignacio Cavalieri
Director del Trabajo Final

1. Descripción técnica-conceptual del proyecto a realizar

El Instituto Nacional de Tecnología Agropecuaria (INTA) es un organismo estatal descentralizado, con independencia operativa y financiera, que se encuentra adscrito a la Secretaría de Agricultura, Ganadería y Pesca del Ministerio de Economía de la Nación. Este ente nació en 1956 con el objetivo de impulsar la innovación y la transferencia de conocimientos en los sectores agroalimentario, agroindustrial y agropecuario a través de la investigación. Sus aportes permiten potenciar el país y generar nuevas oportunidades para acceder a mercados regionales e internacionales con productos y servicios de alto valor agregado.

1.1 Introducción general

La fenómica hace referencia a la obtención de un gran caudal de datos de las características de las plantas, lo que se denomina el fenotipo de la planta. Esta disciplina está en auge en la actualidad debido a sus aplicaciones potenciales. Por un lado, habilita el mejoramiento a gran escala debido a que es necesario vincular una gran cantidad de datos genéticos con datos fenotípicos para identificar la función de los genes. Por otro lado, si se incluyen otros conjuntos de datos como son los climáticos, permite realizar predicciones precisas sobre el comportamiento de las variedades, el cual es necesario para implementar lo que se conoce como agricultura de precisión. Sin embargo, la fruticultura no ha dado el salto hacia la fenómica.

En la Estación Experimental Agropecuaria (EEA) de San Pedro se ha logrado secuenciar el ADN de más de 250 variedades de duraznero (Aballay et al., 2021, Scientific Reports) disponiendo de una base de datos genómica de 75 gigabases (Gb) de ADN. Esta base permite identificar genes que controlan características del duraznero mediante algoritmos de inteligencia artificial (IA). Además, se dispone de datos climáticos diarios que se toman de forma automática que incluyen: las temperaturas medias, precipitaciones, horas de frío, radiación, etc. Esta información se combina con los datos genómicos y posteriormente, con modelos de IA se predice el comportamiento de las variedades en escenarios climáticos futuros.

Por otro lado, las heladas primaverales son actualmente el mayor problema de los frutales a nivel mundial. Este fenómeno ocurre cuando las flores abiertas (estado "F") se someten a temperaturas cercanas a los -2.5°C . Por este motivo, es necesario conocer el número de flores que se encuentran en estado vulnerable ante un pronóstico de heladas, así como también la densidad de flores. Es del interés del INTA determinar el estado fenológico a campo y mejorar para la tolerancia a heladas. Para lograrlo, se empleará IA y visión por computadora.

La visión por computadora es un subdominio de la IA que permite a las máquinas imitar el sistema visual del ser humano. De esta forma, es posible extraer información a partir de imágenes.

En la actualidad existen algoritmos capaces de detectar y clasificar de forma efectiva plantas a través de imágenes. Estos algoritmos se han utilizado para una gran variedad de aplicaciones, como es el caso de reconocimiento de enfermedades en plantas. Sin embargo, aún no se ha desarrollado un sistema para la extracción de estados fenológicos de la flor de durazneros.

La presente propuesta permitirá automatizar la toma de características de la flor de durazneros, a partir de fotos. De esta forma, se logrará aumentar el caudal de datos y mejorar los modelos de IA existentes.

1.2 Marco de la propuesta

La ejecución de este proyecto va alineada con el interés del INTA de determinar el estado de la flor de los durazneros a partir de imágenes.

Las especificaciones de las fotos de varetas que se disponen se detallan en la tabla 1. Por otro lado, las características a determinar se indican en la tabla 2. Se deberá evaluar diferentes modelos de IA a fin de definir el óptimo para esta tarea. Se deberá considerar la existencia de bases de datos de imágenes y/o modelos preentrenados disponibles.

Características de las fotos de duraznos			
Formato	Número	Tamaño	Observaciones
JPG	250	1 MB	Fotos de varetas de duraznero con flores en diferentes estados fenológicos. La mayoría está en estado “F” pero también están en estado “E” y “G”. Cada foto tiene una regla. Cada foto tiene entre 10 a 12 varetas.

Tabla 1. Características de las fotos de duraznos.

Características de interés a ser determinadas	
N° de Flores totales	Presencia de Flor.
Tipo de flor	En las fotos existen dos tipos de flores: campanulácea y rosácea.
Estado fenológico	Discriminar entre estado “F” o flor abierta respecto a los demás estados (“E” flor cerrada o “G” flor sin pétalos).
Densidad de flores	Determinar la cantidad de flores por cm de vareta.

Tabla 2. Características de interés a ser determinadas.

La solución que se propone hará uso de un modelo preentrenado para la detección de flores. Parte del modelado incluirá el ajuste de este algoritmo a las imágenes proporcionadas por el INTA. Como resultado final, se obtendrá un archivo en formato JSON con todos los datos que se detallan en la tabla 2.

La preparación del dataset será una etapa fundamental del proyecto donde se preprocesarán las imágenes, se etiquetarán y se les aplicará data augmentation.

La figura 1 muestra esta solución a alto nivel.

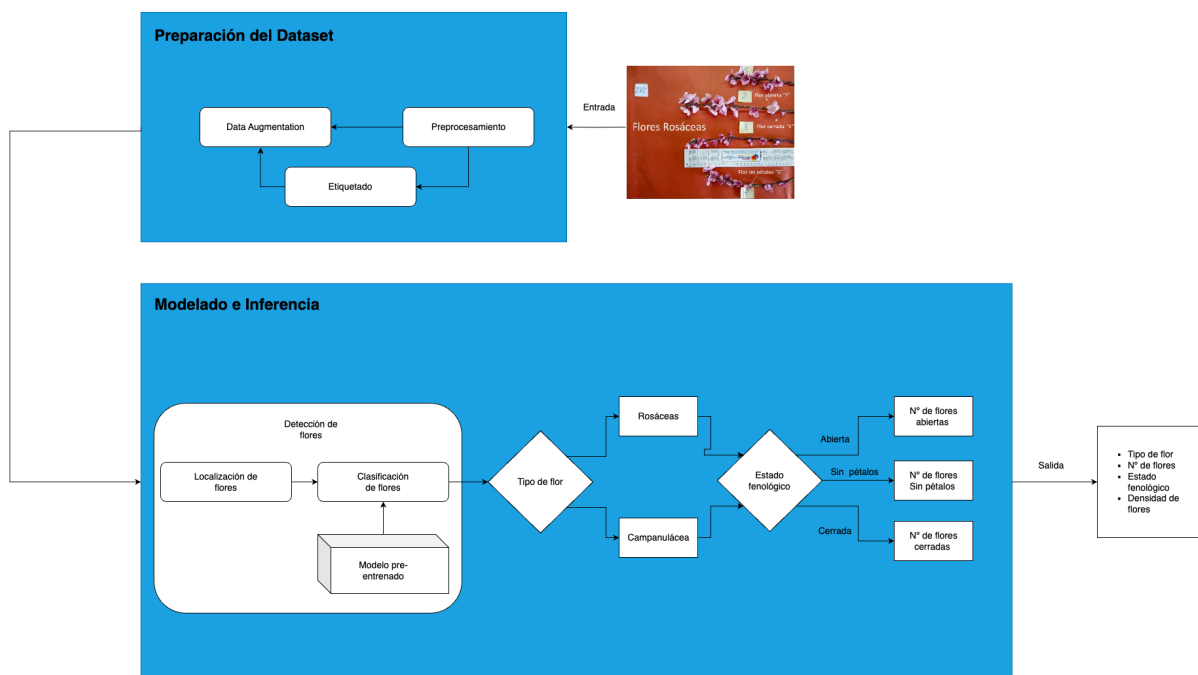


Figura 1. Diagrama en bloques del sistema.

2. Identificación y análisis de los interesados

Rol	Nombre y Apellido	Organización	Puesto
Auspiciante	Dr. Gerardo Sánchez	Instituto Nacional de Tecnología Agropecuaria (INTA)	-
Cliente	Dr. Gerardo Sánchez	Instituto Nacional de Tecnología Agropecuaria (INTA)	-
Responsable	Ing. Héctor Luis Sánchez Márquez	FIUBA	Alumno
Colaboradores	Dr. Maximiliano Aballay	Instituto Nacional de Tecnología Agropecuaria (INTA)	-
Orientador	Ing. Juan Ignacio Cavallieri	FIUBA	Director Trabajo final
Equipo	Dr. Maximiliano Aballay	Instituto Nacional de Tecnología Agropecuaria (INTA)	-
Usuario final	INTA	INTA	-

3. Propósito del proyecto

El propósito de este proyecto es desarrollar un algoritmo que identifique flores de los durazneros y sus estados a partir de fotos de varetas, para aumentar el caudal de datos y mejorar los modelos de IA existentes.

4. Alcance del proyecto

El proyecto incluye:

- El preprocesamiento de las fotos para entrenar el modelo.
- La selección del modelo a entrenar.
- La elaboración del notebook de pruebas en Python.
- La implementación local del modelo.

El proyecto no incluye:

- La recolección de datos/fotos.
- La integración con otros modelos que utilice el cliente.

5. Supuestos del proyecto

Para el desarrollo del presente proyecto se supone que:

- Se contará con suficientes fotos de veretas para entrenar y evaluar el modelo.
- Se contará con soporte para temas no referentes al área de inteligencia artificial que se necesiten para la elaboración de este proyecto.
- Se tendrán imágenes con la calidad adecuada para resolver el problema planteado.
- Se contará con los recursos de hardware necesarios para el entrenamiento del modelo.
- El código se desarrollará en una notebook de Google Colab.

6. Requerimientos

1. Requerimientos funcionales

- 1.1. El sistema tomará como entrada imágenes de varetas de durazneros en formato JPG.
- 1.2. El algoritmo debe detectar la presencia de las varetas de los durazneros e identificar el tipo de flor que posee.
- 1.3. El algoritmo debe identificar el estado fenológico de cada flor de duraznero en la vareta. Este estado puede ser F de flor abierta, E de flor cerrada o G de flor sin pétalos.
- 1.4. El algoritmo debe determinar la cantidad de flores por centímetro de vareta.
- 1.5. El sistema debe entregar como resultado un archivo en formato JSON con los datos detectados por el algoritmo y una imagen donde se puedan visualizar las detecciones.
- 1.6. El sistema debe funcionar en una computadora local.

2. Requerimientos de diseño e implementación

- 2.1. El diseño debe ser modular.
- 2.2. El algoritmo se elaborará en una notebook de Google Colab, utilizando el lenguaje de programación Python y bibliotecas de IA correspondientes.

3. Requerimiento de evaluación y prueba

- 3.1. El modelo se evaluará con imágenes provenientes del mismo dataset de imágenes entregado por el cliente.
- 3.2. Las métricas que se utilizarán para la evaluación del modelo serán: *mean average precision* (mAP), matriz de confusión, *precision*, *recall*, *F1*, *accuracy*.

4. Requerimientos de documentación

- 4.1. El funcionamiento del sistema debe estar correctamente explicado y documentado.
- 4.2. El código en la notebook estará correctamente comentado como parte de buenas prácticas del desarrollo de software.
- 4.3. Inclusión de documentación en un repositorio, mediante un archivo README.md (opcional).

7. Historias de usuarios (*Product backlog*)

Se identifican los siguientes roles:

- Científico: tiene dominio en el problema a resolver. Es el que hará uso de los resultados proporcionados por el algoritmo. Es el que utiliza y proporciona las fotos de las varetas de durazneros.
- Desarrollador de IA: es el que se encarga de mantener el modelo y de desarrollar nuevas funcionalidades.

Para estimar el puntaje de cada historia de usuario se consideran tres aspectos:

- Esfuerzo:
 - Bajo (1).
 - Medio (3).
 - Alto (5).
- Complejidad:
 - Bajo (1).
 - Medio (3).
 - Alto (5).
- Riesgo:
 - Bajo (1).

- Medio (3).
- Alto (5).

Donde el puntaje final es el número de Fibonacci más próximo a la suma de los puntajes parciales.

Se definen las siguientes historias de usuario:

- Como científico, quiero extraer las características de flores de durazneros a través de imágenes usando un modelo de IA, para automatizar este proceso que actualmente se lo realiza de forma manual.
 - Esfuerzo (3): porque el tiempo que se requiere para el desarrollo del modelo y su correcto funcionamiento puede ser medianamente largo.
 - Complejidad (5): porque se requiere de un sólido conocimiento en modelos de aprendizaje basados en visión por computadora.
 - Riesgo (5): porque se pueden presentar imprevistos con las imágenes proporcionadas y compatibilidad con el modelo.
 - Story Point: 13.
- Como desarrollador de IA, quiero contar con un código ordenado que siga las buenas prácticas del desarrollo del software, que esté bien documentado y que esté correctamente versionado, para poder continuar con su mantenimiento y mejora a través del tiempo.
 - Esfuerzo (3): porque el tiempo que se emplea en acomodar el código y dejar todo bien documentado es moderado.
 - Complejidad (3): porque puede incluir una refactorización del código original hecho en la notebook.
 - Riesgo (1): porque no se esperan imprevistos en esta etapa.
 - Story Point: 8.
- Como científico, quiero que el modelo de aprendizaje se pueda ejecutar de forma local en mi computadora de escritorio o laptop para no hacer uso de servidores externos que puedan incrementar el costo del proyecto.
 - Esfuerzo (3): porque el tiempo que se emplea en crear un *endpoint* local es moderado.
 - Complejidad (3): porque existen bibliotecas que facilitan la creación de *endpoints* simples de forma muy rápida e intuitiva.
 - Riesgo (1): porque no se esperan imprevistos en esta etapa.
 - Story Point: 8.

8. Entregables principales del proyecto

Los entregables del proyecto son:

- Esquema del funcionamiento de cada pieza del *pipeline* de IA.
- Notebook con el código del algoritmo.

- Informe de avance.
- Informe final/memoria técnica del proyecto.

9. Desglose del trabajo en tareas

1. Preparación de los datos. (160 h)
 - 1.1. Análisis preliminar de las imágenes. (30 h)
 - 1.2. Estudio y búsqueda de herramientas de etiquetado de elementos en imágenes. (35 h)
 - 1.3. Etiquetado de imágenes. (40 h)
 - 1.4. Aplicar *data augmentation*. (25 h)
 - 1.5. Aplicar redimensionamiento. (20 h)
 - 1.6. Cargar dataset. (10 h)
2. Desarrollo del modelo de IA. (200 h)
 - 2.1. Estudio y búsqueda de modelos preentrenados. (40 h)
 - 2.2. Estudio de arquitecturas de *deep learning* viables. (40 h)
 - 2.3. Desarrollo del modelo usando *transfer learning*. (40 h)
 - 2.4. Entrenamiento del modelo. (40 h)
 - 2.5. Desarrollo de *endpoint*. (40 h)
3. Prueba de desempeño del modelo. (120 h)
 - 3.1. Pruebas sobre datos de validación. (40 h)
 - 3.2. Pruebas sobre el *endpoint* del modelo. (40 h)
 - 3.3. Ajuste y optimización de hiperparámetros. (40 h)
4. Tareas de documentación. (140 h)
 - 4.1. Elaboración de diagramas. (20 h)
 - 4.2. Redacción del informe de avance. (40 h)
 - 4.3. Redacción de la memoria final del proyecto. (40 h)
 - 4.4. Preparación de presentación del proyecto. (40 h)

Cantidad total de horas: 620 h.

10. Diagrama de Activity On Node

La figura 2 ilustra el diagrama de *Activity on Node*. Las tareas están agrupadas por colores y siguiendo la estructura detallada en la sección anterior:

1. Celeste: preparación de los datos.
2. Amarillo: desarrollo del modelo de IA.

3. Lila: prueba de desempeño del modelo.
4. Verde: tareas de documentación.

El camino crítico, cuya duración es de 450 horas, se muestra resaltado en color rojo.

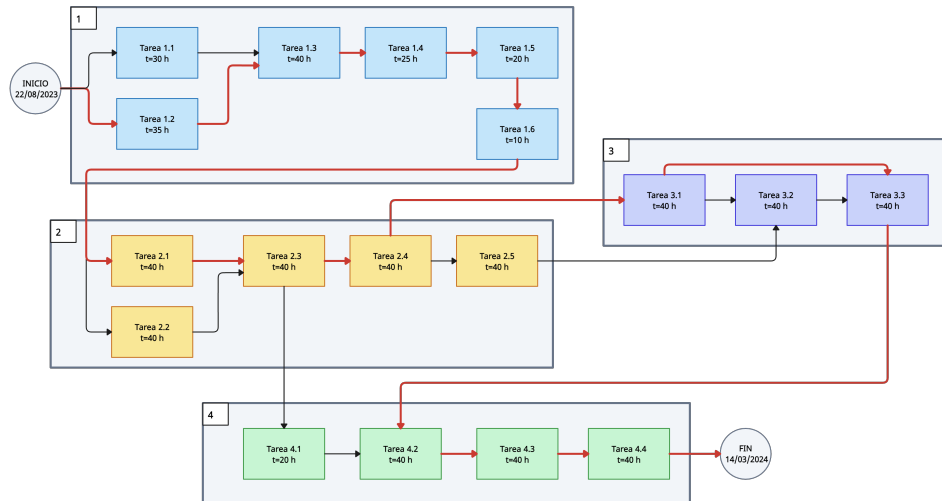


Figura 2. Diagrama de *Activity on Node*.

11. Diagrama de Gantt

En el diagrama de *Activity on Node*, se muestra que algunas tareas pueden ser paralelizables. Sin embargo, en el diagrama de Gantt se mostrarán de forma secuencial debido a que todas estas tareas las estará llevando a cabo el responsable del proyecto. Esto quiere decir, que solo una persona las estará realizando.

El diagrama de Gantt se muestra separado en dos partes. La figura 3 contiene el desglose de tareas y la figura 4 contiene el diagrama propiamente dicho.

ID	Name	Begin date	End date
0	1.1. Análisis preliminar de las imágenes.	8/22/23	8/28/23
2	1.2. Estudio y búsqueda de herramientas de etiquetado de elementos en imágenes.	8/29/23	9/4/23
3	1.3. Etiquetado de imágenes.	9/5/23	9/18/23
5	1.4. Aplicar data augmentation.	9/19/23	9/25/23
6	1.5. Aplicar redimensionamiento.	9/26/23	10/1/23
7	1.6. Cargar dataset.	10/2/23	10/4/23
8	[Hito] Dataset armado y cargado.	10/5/23	10/5/23
9	2.1. Estudio y búsqueda de modelos preentrenados.	10/5/23	10/18/23
10	2.2. Estudio de arquitecturas de deep learning viables.	10/19/23	11/1/23
11	2.3. Desarrollo del modelo usando transfer learning.	11/2/23	11/15/23
12	2.4. Entrenamiento del modelo.	11/16/23	11/29/23
13	2.5. Desarrollo de endpoint.	11/30/23	12/13/23
14	[Hito] Modelo entrenado y endpoint desarrollado.	12/14/23	12/14/23
15	3.1. Pruebas sobre datos de validación.	12/14/23	12/27/23
16	3.2. Pruebas sobre el endpoint del modelo.	12/28/23	1/10/24
17	3.3. Ajuste y optimización de hiperparámetros.	1/11/24	1/24/24
18	[Hito] Modelo probado y optimizado.	1/25/24	1/25/24
19	4.1. Elaboración de diagramas.	1/25/24	1/31/24
20	4.2. Redacción del informe de avance.	2/1/24	2/14/24
21	4.3. Redacción de la memoria final del proyecto.	2/15/24	2/28/24
22	4.4. Preparación de presentación del proyecto.	2/29/24	3/13/24
23	[Hito] Presentación del trabajo.	3/14/24	3/14/24

Figura 3. Desglose de tareas.

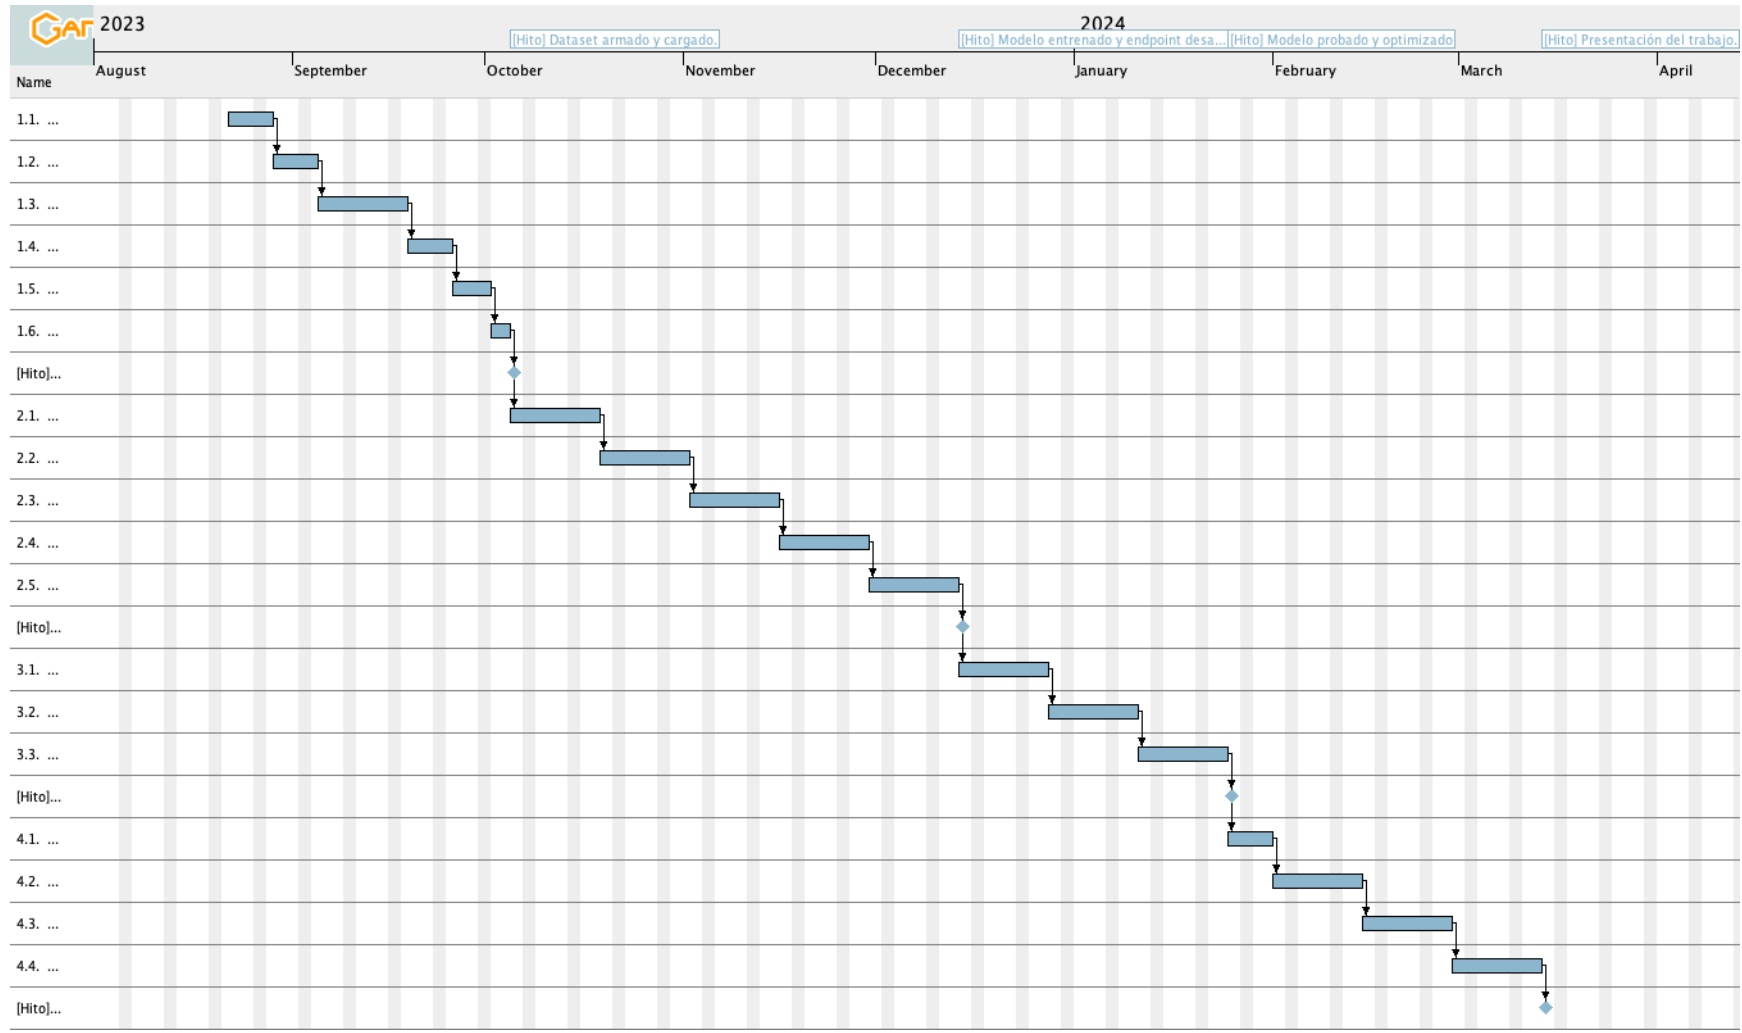


Figura 4. Diagrama de Gantt.

12. Presupuesto detallado del proyecto

A continuación se presenta el presupuesto detallado del proyecto expresado en pesos argentinos:

COSTOS DIRECTOS			
Descripción	Cantidad	Valor unitario	Valor total
Horas de ingeniería	620	\$21.875	\$13.562.500
Computadora personal	1	\$300.000	\$300.000
SUBTOTAL			\$13.862.500
COSTOS INDIRECTOS			
Descripción	Cantidad	Valor unitario	Valor total
Licencia de Roboflow	1	\$70.000	\$70.000
Google Colab pro	1	\$7.000	\$7.000
SUBTOTAL			\$77.000
TOTAL			\$13.939.500

13. Gestión de riesgos

a) Identificación de los riesgos y estimación de sus consecuencias: en esta sección se listan los riesgos que podrían afectar negativamente los planes previstos para este proyecto.

Para el análisis se asignan las siguientes valoraciones:

- Severidad (S) de 1 (bajo) a 10 (alto).
- Probabilidad de ocurrencia (O) de 1 (bajo) a 10 (alto).

Riesgo 1. Datos insuficientes. La cantidad de imágenes proporcionadas es insuficiente o su calidad no es la adecuada para entrenar el modelo.

- Severidad (S): 10. El éxito del modelo esta directamente relacionado con la calidad y cantidad de imágenes que se le proporcione.
- Probabilidad de ocurrencia (O): 8. El INTA cuenta con un conjunto pequeño de imágenes.

Riesgo 2. Etiquetar incorrectamente los estados fenológicos de la flor por falta de conocimiento en el área.

- Severidad (S): 10. El mal etiquetado del conjunto de imágenes influirá en la capacidad del modelo de poder identificar correctamente el estado de las flores.
- Probabilidad de ocurrencia (O): 4. El INTA estará colaborando activamente en el etiquetado para aportar su conocimiento experto en el área.

Riesgo 3. Falta de recursos para entrenar el modelo de aprendizaje.

- Severidad (S): 10. La disponibilidad de recursos de computo y memoria es esencial para que el modelo pueda finalizar su entrenamiento y pueda ejecutar sus predicciones.
- Probabilidad de ocurrencia (O): 7. Al usar Google Colab es probable encontrar falta de disponibilidad de recursos.

Riesgo 4. Bajo desempeño del modelo de aprendizaje para detectar los estados de la flor.

- Severidad (S): 8. No poder detectar correctamente los estados de la flor de duraznero conlleva al no cumplimiento del objetivo principal.
- Probabilidad de ocurrencia (O): 3. La probabilidad de que esto ocurra es baja porque actualmente existen muchos trabajos de investigación que han logrado la detección de plantas en imágenes, lo cual aumenta la posibilidad de que este algoritmo funcione correctamente.

Riesgo 5. Mala interpretación de los requerimientos del cliente y que el algoritmo no preste el servicio esperado.

- Severidad (S): 5. Si el algoritmo no funciona como se desea debido a una mala interpretación, es posible reentrenar el modelo o incluso reemplazarlo, pero afectaría directamente al cronograma del proyecto.
- Probabilidad de ocurrencia (O): 3. La probabilidad de que esto ocurra es baja porque la comunicación con el cliente será continua y los avances se irán informando cada 2 semanas, de forma de detectar cualquier error de este estilo.

b) Tabla de gestión de riesgos: (El RPN se calcula como $RPN = S \times O$)

Riesgo	S	O	RPN	S*	O*	RPN*
1. Datos insuficientes.	10	8	80	6	5	30
2. Etiquetar incorrectamente los estados fenológicos de la flor.	10	4	40	10	2	20
3. Falta de recursos.	10	7	70	10	2	20
4. Bajo desempeño del modelo de aprendizaje.	8	3	24	-	-	-
5. Mala interpretación de los requerimientos.	5	3	15	-	-	-

Criterio adoptado: se tomarán medidas de mitigación en los riesgos cuyos números de RPN sean mayores a 30.

Nota: los valores marcados con (*) en la tabla corresponden luego de haber aplicado la mitigación.

c) Plan de mitigación de los riesgos que originalmente excedían el RPN máximo establecido:

Riesgo 1.

Plan de mitigación: para mitigar este riesgo se tienen tres alternativas. Por un lado, se puede utilizar algoritmos preentrenados usando *transfer learning*, se puede utilizar *data augmentation* o se pueden tomar más imágenes de varetas de duraznero. Ninguna de estas opciones son excluyentes entre sí.

- Severidad (S*): 6. La severidad disminuye debido a que el uso de modelos preentrenados en este tipo de problemas normalmente logra minimizar los efectos de la insuficiencia de datos.
- Probabilidad de ocurrencia (O*): 5. Las probabilidades de que ocurra este riesgo disminuye debido a que esta sugerencia es un procedimiento probado y funcional.

Riesgo 2.

Plan de mitigación: para mitigar este riesgo, se tendrá ayuda de los especialistas del lado del cliente para confirmar que el etiquetado de los estados de la flor en las imágenes sea correcto.

- Severidad (S): 10. La severidad se mantiene.
- Probabilidad de ocurrencia (O*): 2. La probabilidad de que ocurra este riesgo disminuye porque se tendrá una confirmación o verificación del lado del cliente.

Riesgo 3.

Plan de mitigación: para mitigar este riesgo, se utilizará Google Colab pro que cuenta con una mayor disponibilidad de recursos, incluyendo el uso de GPU.

- Severidad (S): 10. La severidad se mantiene.
- Probabilidad de ocurrencia (O*): 2. La probabilidad de que ocurra este riesgo disminuye al aumentar la cantidad de recursos disponibles con la versión pro de Google Colab.

14. Gestión de la calidad

Req #1.2. El algoritmo debe detectar la presencia de las varetas de los durazneros e identificar el tipo de flor que posee.

- Verificación: ejecutar el modelo y verificar visualmente que a la salida, tanto la imagen como el archivo en formato JSON contienen la correcta detección de la vareta y su tipo de flor.
- Validación: procesar una foto de vareta de duraznero con el modelo de IA y obtener a la salida el tipo de flor que posee la vareta.

Req #1.3. El algoritmo debe identificar el estado fenológico de cada flor de duraznero en la vareta. Este estado puede ser F de flor abierta, E de flor cerrada o G de flor sin pétalos.

- Verificación: ejecutar el modelo y verificar visualmente que a la salida, tanto la imagen como el archivo en formato JSON contienen los estados de las flores correctamente identificados.
- Validación: procesar una foto de vareta de duraznero con el modelo de IA y obtener a la salida una imagen y un archivo en formato JSON con la información de los estados fenológicos de las flores.

Req #1.4. El algoritmo debe determinar la cantidad de flores por centímetro de vareta.

- Verificación: ejecutar el modelo y comprobar en el archivo en formato JSON de salida si el número total de flores detectadas por centímetro de vareta coincide con lo que se visualiza en la imagen.
- Validación: procesar una foto de vareta de duraznero con el modelo de IA y extraer la cantidad de flores por centímetro de vareta sin errores.

Req #1.5. El sistema debe entregar como resultado un archivo en formato JSON con los datos detectados por el algoritmo y una imagen donde se puedan visualizar las detecciones.

- Verificación: ejecutar el modelo y verificar que a la salida se obtiene un archivo en formato JSON y una imagen con las detecciones.
- Validación: procesar una foto de vareta de duraznero con el algoritmo y obtener un archivo en formato JSON con las características de las flores y adicionalmente la imagen con las detecciones.

Req #1.6. El sistema debe funcionar en una computadora local.

- Verificación: dejar funcionando el modelo de aprendizaje en una computadora local y que este no arroje ningún tipo de error.
- Validación: activar el modelo de aprendizaje en la computadora local y empezar a correr inferencias.

Req #2.1. El diseño debe ser modular.

- Verificación: visualizar en la *notebook* que cada parte del *pipeline* de procesamiento esté correctamente seccionado por funciones.
- Validación: inspeccionar que el código sea modular.

Req #3.2. Las métricas que se utilizarán para la evaluación del modelo serán: *mean average precision* (mAP), matriz de confusión, *precision*, *recall*, *F1*, *accuracy*.

- Verificación: visualizar que al final del entrenamiento del modelo, las métricas con las que se evalúa al sistema, sean las mencionadas en los requerimientos.
- Validación: inspeccionar en la *notebook* las métricas que definen el rendimiento del mejor modelo.

Req #4.1. El funcionamiento del sistema debe estar correctamente explicado y documentado.

- Verificación: no aplica.

- Validación: inspeccionar la documentación proporcionada.

Req #4.2. El código en la *notebook* estará correctamente comentado como parte de buenas prácticas del desarrollo de software.

- Verificación: revisar que cada sección del código este correctamente comentada.
- Validación: inspeccionar los comentarios en el código y verificar que sean comprensibles.

15. Procesos de cierre

A continuación se describen las pautas que darán cierre al proyecto:

- Pautas de trabajo que se seguirán para analizar si se respetó el Plan de Proyecto original:
 - El responsable del proyecto comparará la planificación inicial del cronograma y los tiempos de ejecución reales del proyecto.
 - El responsable del proyecto verificará si las tareas planteadas inicialmente correspondieron a la ejecución real.
- Identificación de las técnicas y procedimientos útiles e inútiles que se emplearon, y los problemas que surgieron y cómo se solucionaron:
 - El responsable del proyecto con ayuda de su director examinarán los procesos fallidos y exitosos que se dieron durante el desarrollo del proyecto.
 - El responsable del proyecto documentará todos los procesos fallidos y exitosos que se obtuvieron.
- Indicar quién organizará el acto de agradecimiento a todos los interesados, y en especial al equipo de trabajo y colaboradores:
 - Posterior a la defensa pública, el responsable del proyecto se encargará de dar el reconocimiento al mérito de cada uno de los involucrados en este proyecto.